

Robótica Móvel

Revisão de probabilidade

Prof. Douglas G. Macharet
douglas.macharet@dcc.ufmg.br

Introdução

- Robótica é a ciência de observar e manipular o mundo físico por dispositivos mecânicos controlados a partir de um computador
- Principal problema → Incertezas
 - **Ambiente:** não-estruturados, altamente dinâmicos e imprevisíveis
 - **Sensores:** limitados na percepção (alcance e resolução)
 - **Atuadores:** motores e mecanismos são fonte de erros
 - **Modelos:** abstrações/simplificações do mundo real

Introdução

- Robótica probabilística

“A robot that carries a **notion of its own uncertainty** and that **acts accordingly** is superior to one that does not.”

– Probabilistic Robotics

- Objetivo

- Representação explícita da incerteza
- Cálculo baseado na teoria da probabilidade

Introdução

- Estimar estados a partir de informações sensoriais
 - Aproximar uma informação (quantidade) que não é diretamente observável, mas pode ser inferida a partir dos dados dos sensores
- Algoritmos de estimação probabilísticos
 - Distribuições de “possibilidades” sobre estados (robô/mundo)
- Loop de execução
 - **Ação** → otimização da utilidade
 - **Observação** → estimativa do estado

Conceitos básicos

- Como o robô não tem certeza, ele possui um grau de crença (confiança) sobre a informação sendo estimada
- Esse valor é constantemente atualizado à medida que novas informações (evidências) são recebidas (observadas)
 - *Prior* : Probabilidade Incondicional (antes)
 - *Posterior* : Probabilidade Condicional (depois)


Conceitos básicos

Variável aleatória

- Informação do mundo com incerteza
- Possui um domínio de valores
 - Discreta, Contínua
- Notação
 - X uma variável aleatória e x um certo evento
 - $p(X = x) \rightarrow p(x)$
 - $p(X = \text{cara}) = p(X = \text{coroa})$

Probabilidade Incondicional

- Probabilidade de ocorrência de um certo evento dado que não temos nenhuma outra informação a seu respeito
 - $p(\text{Moeda} = \text{cara}) = 1/2$
 - $p(\text{Dado} = 2) = 1/6$
- Distribuição de probabilidades: espaço de valores
 - Probability Mass Function (PMF)
 - $p(\text{Moeda}) = \langle 0.5, 0.5 \rangle$
 - $p(\text{Dado}) = \langle \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6} \rangle$



Probabilidade Incondicional

- Variáveis aleatórias contínuas
 - Qualquer valor numérico dentro de um intervalo
- Distribuição de probabilidades: Probability Density Function (PDF)


$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Diagram illustrating the components of the Normal Distribution PDF formula:

- μ (Mean): Indicated by a blue arrow pointing to the mean symbol in the exponent.
- σ (Standard Deviation): Indicated by an orange arrow pointing to the standard deviation symbol in the denominator.
- σ^2 (Variance): Indicated by a green arrow pointing to the variance symbol in the denominator.

Labels in Portuguese:

- Média (Mean)
- Desvio padrão (Standard Deviation)
- Variância (Variance)



Probabilidade Conjunta

- Probabilidade que dois eventos aconteçam simultaneamente
- Probabilidade conjunta de variáveis aleatórias
 - $p(x, y) = p(X = x \wedge Y = y)$
- Se X e Y são independentes
 - $p(x, y) = p(x) p(y)$
- Exemplo: 2 dados não viciados
 - $p(X = 1 \wedge Y \neq 1) = \frac{1}{6} \cdot \frac{5}{6} = 5/36$

Probabilidade Condicional

- Algumas vezes, as variáveis aleatórias podem carregar informações sobre outras variáveis aleatórias no contexto
- Probabilidade de $X = x$, condicionado ao fato que $Y = y$
 - $p(x | y) = p(X = x | Y = y)$
 - “Probabilidade condicional de x dado y .”
 - “Qual a probabilidade de x se y é verdadeiro/ocorreu?”

Probabilidade Condicional

- Se $p(y) > 0$, a probabilidade condicional é

$$p(x | y) = \frac{p(x, y)}{p(y)} \rightarrow p(x, y) = p(x | y)p(y)$$

Regra do produto

- Se X e Y são independentes, então

$$p(x | y) = \frac{p(x)p(y)}{p(y)} = p(x)$$

Probabilidade Marginal

- Probabilidade do evento A ocorrer, independentemente de qualquer outro evento B , ou seja, deixando o evento B à margem do problema
- A probabilidade marginal de A é

$$p(A) = p(A|B)p(B) + p(A|\neg B)p(\neg B)$$

- onde $\neg B$ representa o caso onde B não ocorre

Lei da Probabilidade Total

- Relaciona probabilidades marginais e probabilidades condicionais
 - Difícil calcular a probabilidade do evento A de forma direta
 - Probabilidade do resultado inferido através de eventos distintos
- Caso discreto
 - $p(x) = \sum_y p(x, y) \Rightarrow p(x) = \sum_y p(x | y)p(y)$
- Caso contínuo
 - $p(x) = \int_y p(x, y) dy \Rightarrow p(x) = \int_y p(x | y)p(y)dy$

Lei da Probabilidade Total

Exemplo

- Dado um baralho comum, qual a probabilidade de se escolher um Ás ao retirar uma carta aleatoriamente?

$$p(\text{Ás} \mid \text{ouros}) = \frac{1}{13} \quad p(\text{ouros}) = \frac{1}{4}$$

$$p(\text{Ás} \mid \text{copas}) = \frac{1}{13} \quad p(\text{copas}) = \frac{1}{4}$$

$$p(\text{Ás} \mid \text{paus}) = \frac{1}{13} \quad p(\text{paus}) = \frac{1}{4}$$

$$p(\text{Ás} \mid \text{espadas}) = \frac{1}{13} \quad p(\text{espadas}) = \frac{1}{4}$$

$$p(x) = \sum_y p(x \mid y)p(y) = \left(\frac{1}{13} \cdot \frac{1}{4} \right) \cdot 4 = \frac{1}{13}$$

Teorema de Bayes

- Papel fundamental na robótica probabilística
- Geralmente a informação é em uma direção
 - Causa \rightarrow Efeito
 - Estar em q (estado) faz os sensores retornarem z (observação)
- Regra de Bayes permite obter o inverso, ou seja, uma vez observado o efeito (evidência), qual é a causa mais provável

Teorema de Bayes

- A partir da regra do produto

$$p(x, y) = p(x | y)p(y)$$

$$p(x, y) = p(y | x)p(x)$$



$$p(x | y) = \frac{p(y | x)p(x)}{p(y)} = \frac{\text{likelihood} \cdot \text{prior}}{\text{evidence}}$$

Teorema de Bayes

Likelihood

Probabilidade de observar essa evidência quando nossa hipótese é verdadeira.

Prior

Probabilidade da hipótese ser verdadeira antes de observar alguma evidência.

$$p(H|E) = \frac{p(E|H)p(H)}{p(E)}$$

Posterior

Probabilidade da hipótese ser verdadeira considerando a evidência (dado) observada.

Marginal

Qual a probabilidade de se observar essa evidência dada todas as possíveis hipóteses?

Dica: <https://youtu.be/HZGCoVF3YvM>

Teorema de Bayes

Exemplo

- Diagnóstico médico
 - Meningite causa torcicolo em 50% dos casos
 - Fatos incondicionais (*prior*)
 - Probabilidade de ter meningite: $1/50000$
 - Probabilidade de ter torcicolo: $1/20$
 - Estou com torcicolo, tenho meningite?

$$p(m) = 1/50000 \qquad p(s) = 1/20 \qquad p(s | m) = 0.5$$

$$p(m | s) = \frac{p(s | m) p(m)}{p(s)} = \frac{0.5 \cdot 1/50000}{1/20} = 0.0002$$

Teorema de Bayes

Normalização

- Como observado, $p(y)$ não depende de x
 - Terá o mesmo valor para todo x em $p(x | y)$
- Geralmente usado como um **fator normalizador**

$$p(x | y) = \frac{p(y | x)p(x)}{p(y)} = \eta p(y | x)p(x)$$

$$\eta = p(y)^{-1} = \frac{1}{\sum_{x'} p(y|x')p(x')}$$

Teorema de Bayes

Múltiplas evidências

- Finalmente, podemos condicionar qualquer uma das regras em outras variáveis aleatórias (evidências anteriores)

$$p(x \mid y, z) = \frac{p(y \mid x, z)p(x \mid z)}{p(y \mid z)}$$

- Condicionando probabilidades conjuntas independentes

$$p(x, y \mid z) = p(x \mid z)p(y \mid z)$$

Conhecido como independência condicional.

Teorema de Bayes

Independência condicional

- Eventos x e y condicionalmente independentes de z se

$$p(x, y | z) = p(x|z)p(y|z)$$

- Isso é equivalente a


$$p(x | z) = p(x | z, y) \quad \text{e} \quad p(y | z) = p(y | z, x)$$

- Independência absoluta/condicional

$$p(x, y) = p(x)p(y) \not\Leftrightarrow p(x, y|z) = p(x|z)p(y|z)$$

Teorema de Bayes

Independência condicional



$$p(x) = 0.5$$

$$p(y) = 0.375$$

$$p(x, y) = 0.125$$


$$p(x)p(y) = 0.1875$$

$$p(x, y) \neq p(x)p(y)$$

Não são independentes!

Teorema de Bayes

Independência condicional



$$p(x) = 0.5$$

$$p(y) = 0.375$$

$$p(x | z) = 0.5$$

$$p(y | z) = 0.5$$


$$p(x, y | z) = 0.25$$

$$p(x, y | z) = p(x|z)p(y|z)$$

Condicionalmente independentes!

Exemplo

- Robô deve estimar o estado de uma porta usando sua câmera
- Supondo que o robô obtém uma medição z , qual é $p(\text{open} \mid z)$?



Exemplo

- $p(\text{open} \mid z) \rightarrow$ Efeito
- $p(z \mid \text{open}) \rightarrow$ Causa (sensor model)
 - Geralmente fácil de ser obtido
 - Como? \rightarrow Fazer várias leituras e as estatísticas necessárias.
- Teorema de Bayes permite usar essa informação

$$p(\text{open} \mid z) = \frac{p(z \mid \text{open})p(\text{open})}{p(z)}$$

Exemplo

- $p(z \mid \text{open}) = 0.6$ $p(z \mid \neg\text{open}) = 0.3$
- $p(\text{open}) = p(\neg\text{open}) = 0.5$

$$p(\text{open} \mid z) = \frac{p(z \mid \text{open})p(\text{open})}{p(z \mid \text{open})p(\text{open}) + p(z \mid \neg\text{open})p(\neg\text{open})}$$

$$p(\text{open} \mid z) = \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = 0.66$$


Exemplo

- Ou seja, a leitura atual nos ajudou a aumentar a confiança que a porta está aberta considerando a estimativa inicial
- O robô obtém uma nova observação z_2 , como fazer agora para integrar a nova observação à estimativa anterior?
- De forma mais geral, como estimar $p(x|z_1 \dots z_n)$?

Exemplo

■ Atualização Bayesiana Recursiva

$$p(x | y, z) = \frac{p(y | x, z)p(x | z)}{p(y | z)}$$



$$p(x | z_1, \dots, z_n) = \frac{p(z_n | x, z_1, \dots, z_{n-1})p(x | z_1, \dots, z_{n-1})}{p(z_n | z_1, \dots, z_{n-1})}$$

Exemplo

- Suposição de Markov

- z_n é condicionalmente independente de z_1, \dots, z_{n-1} dado x

$$\begin{aligned} p(x|z_1, \dots, z_n) &= \frac{p(z_n|x)p(x|z_1, \dots, z_{n-1})}{p(z_n|z_1, \dots, z_{n-1})} \\ &= \eta p(z_n|x)p(x|z_1, \dots, z_{n-1}) \\ &= \eta_{1\dots n} \prod_{i=1\dots n} p(z_i|x)p(x) \end{aligned}$$

Exemplo

- $p(z_2 \mid \text{open}) = 0.5$ $p(z_2 \mid \neg\text{open}) = 0.6$
- $p(\text{open} \mid z_1) = 0.66$

$$p(\text{open} \mid z_2, z_1) = \frac{p(z_2 \mid \text{open})p(\text{open} \mid z_1)}{p(z_2 \mid \text{open})p(\text{open} \mid z_1) + p(z_2 \mid \neg\text{open})p(\neg\text{open} \mid z_1)}$$

$$p(\text{open} \mid z_2, z_1) = \frac{0.5 \cdot 0.66}{0.5 \cdot 0.66 + 0.6 \cdot 0.33} = 0.625$$

A segunda leitura reduziu a
confiança da porta estar aberta!

Ações

- O mundo é dinâmico, pode ser alterado
 - Por ações realizadas pelo próprio robô
 - Por ações realizadas por outros agentes
 - Pelo simples fato do passar do tempo
- As ações ajudam ou atrapalham?
 - Essas ações também são incertas!
 - Movimento das rodas, uso do manipulador, ...
- Como incorporar isso no modelo?


- Para incorporar a influência das ações no estado de crença, vamos fazer uso da probabilidade condicional

$$p(x_t \mid u, x_{t-1})$$

- O termo especifica a probabilidade de se chegar no estado x_t estando atualmente em x_{t-1} e aplicando a ação de controle u


Exemplo

- Foi enviado um comando para o robô fechar uma porta
- Como determinar (estimar) se a porta foi efetivamente fechada?



Exemplo

- Temos $p(x_t | u, x_{t-1})$ onde u é “fechar a porta”



- Ou seja, se a porta estiver aberta, a ação “fechar a porta” obtém sucesso em 90% dos casos (a porta é fechada)

Integrando ações

- Caso discreto

$$p(x_t | u) = \sum p(x_t | u, x_{t-1})p(x_{t-1})$$

- Caso contínuo

$$p(x_t | u) = \int p(x_t | u, x_{t-1})p(x_{t-1})dx_{t-1}$$

Exemplo

$$\begin{aligned} p(\text{closed} \mid u) &= \sum p(\text{closed} \mid u, x_{t-1})p(x_{t-1}) \\ &= p(\text{closed} \mid u, \text{open})p(\text{open}) + p(\text{closed} \mid u, \text{closed})p(\text{closed}) \\ &= \frac{9}{10} \cdot \frac{5}{8} + \frac{1}{1} \cdot \frac{3}{8} = \frac{15}{16} \end{aligned}$$

$$\begin{aligned} p(\text{open} \mid u) &= \sum p(\text{open} \mid u, x_{t-1})p(x_{t-1}) \\ &= p(\text{open} \mid u, \text{open})p(\text{open}) + p(\text{open} \mid u, \text{closed})p(\text{closed}) \\ &= \frac{1}{10} \cdot \frac{5}{8} + \frac{0}{1} \cdot \frac{3}{8} = \frac{1}{16} \\ &= 1 - p(\text{closed} \mid u) \end{aligned}$$

Filtro de Bayes

■ Fornecido


- Conjunto de ações e observações: $d_t = \{u_1, z_1, \dots, u_{t-1}, z_t\}$
- Modelo de **transição**: $p(x_t | u_t, x_{t-1})$
- Modelo de **observação**: $p(z_t | x_t)$
- Estado a priori do sistema: $p(x)$

■ Desejado

- O estado a posteriori, chamado de crença (*Belief*)
- $bel(x_t) = p(x_t | z_{1:t}, u_{1:t})$ Distribuição de probabilidade sobre o estado x_t , condicionada a todas as observações e ações.

Filtro de Bayes

Modelo Gráfico Probabilístico



$$p(x_t \mid x_{0:t-1}, z_{1:t-1}, u_{1:t}) = p(x_t \mid x_{t-1}, u_t) \quad \text{(ação)}$$

$$p(z_t \mid x_{0:t}, z_{1:t-1}, u_{1:t}) = p(z_t \mid x_t) \quad \text{(observação)}$$

Filtro de Bayes

```
1:   Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:     for all  $x_t$  do  
3:        $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:        $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:     endfor  
6:     return  $bel(x_t)$ 
```

Filtro de Bayes

■ Predição

$$\bar{bel}(x_t) = \int \underbrace{p(x_t | u_t, x_{t-1})}_{\text{Modelo de transição}} bel(x_{t-1}) dx_{t-1}$$

■ Correção

$$bel(x_t) = \eta \underbrace{p(z_t | x_t)}_{\text{Modelo de observação}} \bar{bel}(x_t)$$

Veja toda a derivação no livro-texto, Capítulo 2.

Considerações finais

- Modelo de transição
 - Descreve a probabilidade de transição/evolução do estado
- Modelo de observação
 - Descreve o processo de formação pelo qual as medições de um sensor específico são geradas no mundo físico
- Leia mais no livro
 - Modelo de transição: Capítulo 5
 - Modelo de observação: Capítulo 6