

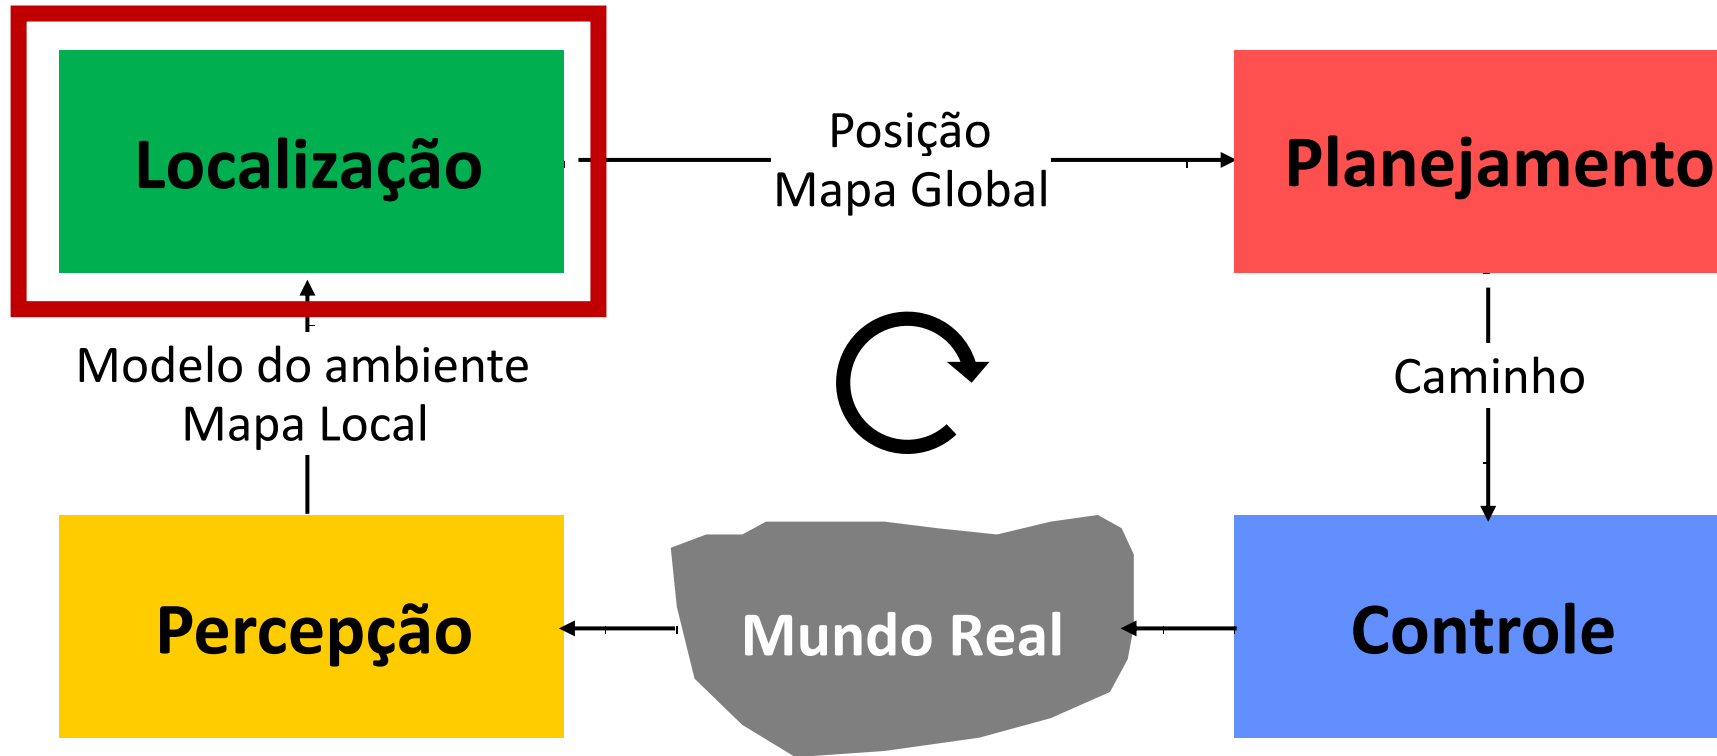
# Robótica Móvel

## Localização – Filtro de Kalman

---


Prof. Douglas G. Macharet  
douglas.macharet@dcc.ufmg.br

# Introdução



# Introdução

- Principais questões na Robótica
  - **Onde estou?** (localização)
  - Aonde vou? (decisão)
  - Como vou? (planejamento)




# Localização


- Tarefa fundamental
  - Determinar a configuração (*pose*) do robô
- Diferentes representações
  - Coordenadas (métrica), topológica, ...
- Relativa x Absoluta
  - Sempre é relativa a um referencial
  - Referencial Local (não compartilhado) x Global (fixo)

# Localização

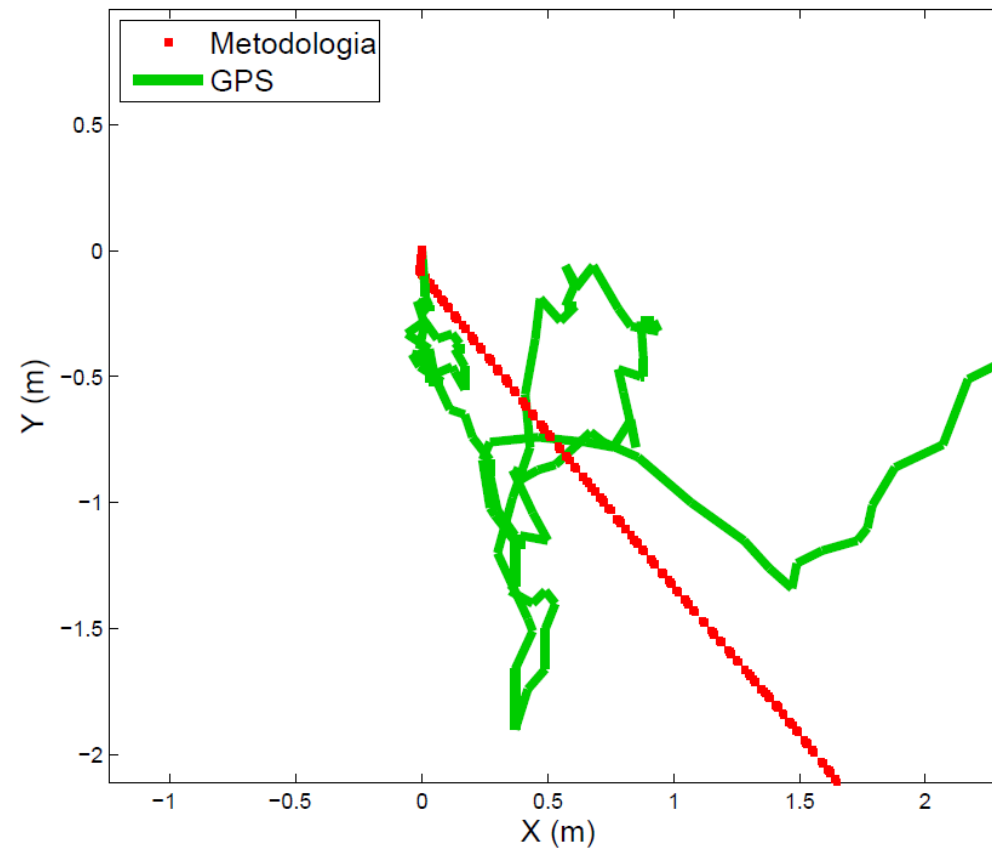
- Principais desafios
  - Erros nos sensores
    - Ruído
    - *Aliasing*
  - Erros nos atuadores
  - Erros nos modelos (simplificações)



# Localização



- Por que não utilizar sempre GPS?
  - Não está disponível em todos os ambientes
    - Edificações, cavernas, subaquático, Marte, ...
  - Baixo desempenho para sistemas mais críticos 
    - Precisão
    - Taxa de aquisição de dados
    - Tamanho do receptor
    - *Random walk*

# Localização



# Localização

## Odometria



**Erro sistemático, talvez uma calibração resolvesse. Seria o suficiente?**



# Localização

- Fusão Sensorial
  - Juntar informações ruidosas para termos algo melhor!
- Principais formas de localização
  - *Dead reckoning* (relativa)
    - Filtro de Kalman
  - Baseada em marcos/mapas (absoluta)
    - Localização de Markov
    - Localização de Monte Carlo

# Filtro de Kalman

- Aplicação direta do Filtro de Bayes
  - R. E. Kalman (1950's)
- Estimação recursiva de estados
  - Predição → Correção
- Diferentes aplicações
  - Projeto Apollo
  - Fusão sensorial, estimação, filtragem, ...

[https://en.wikipedia.org/wiki/Kalman\\_filter](https://en.wikipedia.org/wiki/Kalman_filter)

<https://www.mathworks.com/videos/series/understanding-kalman-filters.html>

# Filtro de Kalman

- Quando utilizar
  - Medidas obtidas por diferentes sensores
  - Variáveis de interesse obtidas indiretamente

Considera que o sistema é linear e pode ser representado por distribuições gaussianas

# Filtro de Kalman


- Condições para a otimalidade da técnica
- Hipóteses
  - Erro médio de cada variável é igual a zero (*white Gaussian noise*)
  - Erro de cada variável é independente
  - Modelo linear de evolução do sistema (linearizado)
  - Relacionamento linear entre as variáveis de estado e observação

# Filtro de Kalman

## Gaussianas


### ■ 1D

$$\begin{aligned} p(x) &= N(\mu, \sigma^2) \\ &= \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \end{aligned}$$



### ■ nD

$$\begin{aligned} p(x) &= N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &= \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2}} e^{-\frac{(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2}} \end{aligned}$$



# Filtro de Kalman

## Gaussianas

- A variância de uma variável aleatória  $X$  é o valor esperado do desvio ao quadrado da média,  $\mu = E[X]$ :  $\sigma^2 = E[(X - \mu)^2]$
- A covariância de duas ou mais variáveis aleatórias é uma medida da variabilidade conjunta dessas variáveis

$$\text{cov}[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$


- A matriz de covariância  $\Sigma$  possui  $(i, j)$  como  $\text{cov}[X_i, X_j]$

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T] = E[\mathbf{X}\mathbf{X}^T] - \mu\mu^T$$


random vector  $\leftarrow$   $\mathbf{X}$   $\rightarrow$   $E[\mathbf{X}]$

# Filtro de Kalman


## Gaussianas



$$\mu = [0, 0]$$
$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$




$$\mu = [0, 0]$$
$$\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\mu = [0, 0]$$
$$\Sigma = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}$$

# Filtro de Kalman

## Gaussianas – Estado de crença



$$p(x) = N(\mu, \Sigma)$$

$$\mu = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix} \quad \Sigma = \begin{bmatrix} \sigma_x \sigma_x & \sigma_x \sigma_y & \sigma_x \sigma_\theta \\ \sigma_y \sigma_x & \sigma_y \sigma_y & \sigma_y \sigma_\theta \\ \sigma_\theta \sigma_x & \sigma_\theta \sigma_y & \sigma_\theta \sigma_\theta \end{bmatrix}$$

Variância ←



# Filtro de Kalman

## Gaussianas – Operações

- Considerando as variáveis
  - $x_1 = N(\mu_1, \sigma_1^2)$  e  $x_2 = N(\mu_2, \sigma_2^2)$
  - Qual o resultado para  $y = f(x_1, x_2)$ ?
- Se  $f$  é linear,  $x_1, x_2$  independentes e normais  $\rightarrow$  gaussiana
  - $y = Ax_1 + Bx_2$
  - $y = N(A\mu_1 + B\mu_2, A^2\sigma_1^2 + B^2\sigma_2^2)$  (1D)
  - $y = N(A\mu_1 + B\mu_2, A\Sigma_1A^T + B\Sigma_2B^T)$  (2D)

# Filtro de Kalman

## Gaussianas – Operações

- O produto de Gaussianas também é uma Gaussiana
- 1D


$$\left. \begin{array}{l} x_1 = N(\mu_1, \sigma_1^2) \\ x_2 = N(\mu_2, \sigma_2^2) \end{array} \right\} \Rightarrow p(x_1) \cdot p(x_2) = N\left(\frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} \mu_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \mu_2, \frac{1}{\sigma_1^{-2} + \sigma_2^{-2}}\right)$$

- $n$ D

$$\left. \begin{array}{l} x_1 = N(\mu_1, \Sigma_1) \\ x_2 = N(\mu_2, \Sigma_2) \end{array} \right\} \Rightarrow p(x_1) \cdot p(x_2) = N\left(\frac{\Sigma_2}{\Sigma_1 + \Sigma_2} \mu_1 + \frac{\Sigma_1}{\Sigma_1 + \Sigma_2} \mu_2, \frac{1}{\Sigma_1^{-1} + \Sigma_2^{-1}}\right)$$

# Filtro de Kalman

## Gaussianas – Operações



# Filtro de Kalman

## Gaussianas – Exemplo (fusão sensorial)


- Considerando uma posição  $q$  e duas estimativas (*belief*)
  - $p_1(q) = N(\hat{q}_1, \sigma_1^2)$  (ação  $\rightarrow$  predição)
  - $p_2(q) = N(\hat{q}_2, \sigma_2^2)$  (observação  $\rightarrow$  correção)
- Como estimar a distribuição final resultante  $p(q)$ ?
- Produto das estimativas
  - $p(q) = p_1(q) \cdot p_2(q) = N(q, \sigma^2)$

# Filtro de Kalman

## Gaussianas – Exemplo (fusão sensorial)

$$\underbrace{\frac{1}{\sigma_1 \sqrt{2\pi}} \exp\left(-\frac{(q-\hat{q}_1)^2}{2\sigma_1^2}\right)}_{p_1(q)} \cdot \underbrace{\frac{1}{\sigma_2 \sqrt{2\pi}} \exp\left(-\frac{(q-\hat{q}_2)^2}{2\sigma_2^2}\right)}_{p_2(q)} = \frac{1}{\sigma_1 \sigma_2 \sqrt{2\pi}} \exp\left(-\frac{(q-\hat{q}_1)^2}{2\sigma_1^2} - \frac{(q-\hat{q}_2)^2}{2\sigma_2^2}\right)$$

Gaussiana  $\rightarrow \Omega \exp\left(-\frac{(q-\hat{q})^2}{2\sigma^2}\right)$



$$\hat{q} = \underbrace{\frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}}_{W_1} \hat{q}_1 + \underbrace{\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}}_{W_2} \hat{q}_2$$


$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

# Filtro de Kalman

## Gaussianas – Exemplo (fusão sensorial)


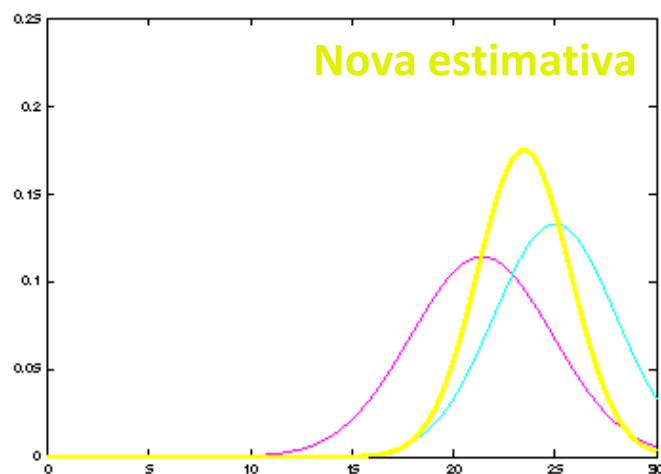

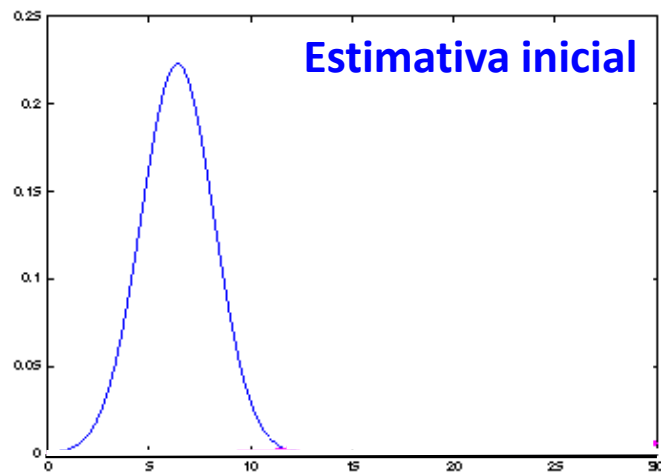
$$\hat{q} = \hat{q}_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} (\hat{q}_2 - \hat{q}_1)$$

$$\sigma^2 = \sigma_1^2 - \frac{\sigma_1^4}{\sigma_1^2 + \sigma_2^2}$$



- Variância resultante **menor** que as variâncias de entrada
- Até observações ruidosas ajudam a melhorar a estimativa

# Filtro de Kalman



# Filtro de Kalman

- Crença  $bel(x_t)$  no tempo  $t$  pela média  $\mu_t$  e covariância  $\Sigma_t$
- Implementação de “mínimos quadrados”
  - Encontrar o melhor ajuste para um conjunto de dados
- Estimação de estados
  - Passado, presente, futuro
- Medida da qualidade da estimativa
  - Variância associada
- Método robusto



# Filtro de Kalman

- Estimar o estado  $x$  de um processo em tempo discreto
- Processo possui dinâmica linear dada pela equação

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

- Modelo de observação linear dado por

$$z_t = C_t x_t + \delta_t$$

# Filtro de Kalman

## Componentes

- $A_t$  : Matriz ( $n \times n$ ) que representa a evolução do estado de  $t - 1$  para  $t$  sem ações de controle ou ruído ( $n$  é a dimensão do vetor de estado  $x$ )
- $B_t$  : Matriz ( $n \times m$ ) que descreve como as ações de controle  $u_t$  mudam o estado de  $t - 1$  para  $t$  ( $m$  é a dimensão do vetor de controle  $u$ )
- $C_t$  : Matriz ( $k \times n$ ) que descreve como mapear o estado  $x_t$  em uma observação  $z_t$  ( $k$  é a dimensão do vetor de observações  $z$ )
- $\varepsilon_t, \delta_t$  : São variáveis aleatórias que representam os ruídos de processo e observação, assumidos como independentes e com distribuição normal com covariância  $R_t$  e  $Q_t \rightarrow \varepsilon_t = N(0, R_t), \delta_t = N(0, Q_t)$

# Filtro de Kalman


## Ilustração

Estado de crença inicial

Incerteza aumenta por uma ação

Incerteza diminui após observação

Repete o processo



# Filtro de Kalman

## Filtro de Bayes

- Valor a posteriori do estado (*belief*)
  - $bel(x_t) = p(x_t | z_{1:t}, u_{1:t})$
- Predição
  - $\overline{bel}(x_t) = \int p(x_t | x_{t-1}, u_t) bel(x_{t-1}) dx_{t-1}$
- Correção
  - $bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$

# Filtro de Kalman

## Filtro de Bayes

### ■ Predição

$$\text{■ } \overline{bel}(x_t) = \int \underbrace{p(x_t | x_{t-1}, u_t)}_{\text{blue}} \underbrace{bel(x_{t-1})}_{\text{black}} dx_{t-1}$$

$$N(A_t x_{t-1} + B_t u_t, R_t) \leftarrow \quad \rightarrow N(\mu_{t-1}, \Sigma_{t-1})$$

$$\text{■ } \overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t \end{cases}$$

# Filtro de Kalman

## Filtro de Bayes

### ■ Correção

- $bel(x_t) = \underbrace{\eta p(z_t|x_t)}_{N(C_t x_t, Q_t)} \underbrace{\overline{bel}(x_t)}_{N(\bar{\mu}_t, \bar{\Sigma}_t)}$

- $bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \bar{\Sigma}_t \end{cases}$


- onde  $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$

# Filtro de Kalman

## Ganho de Kalman


- Ganho de Kalman ( $K_t$ )
  - Grau que a medição é incorporada na nova estimativa do estado
  - Manipula a média  $\mu_t$  ajustando-a proporcionalmente de acordo com o ganho e o desvio da medição feita e a medição prevista

$$K = \frac{E_{est}}{E_{est} + E_{mea}}$$



# Filtro de Kalman

## Ganho de Kalman



Estimativas são mais estáveis  
e as Medições são imprecisas

Medições são precisas, mas  
as Estimativas são instáveis



# Filtro de Kalman

## Algoritmo


```
1:  Algorithm Kalman_filter( $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$ ):  
2:       $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$   
3:       $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$   
4:       $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$   
5:       $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$   
6:       $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$   
7:      return  $\mu_t, \Sigma_t$ 
```

**Predição**


**Correção**

# Filtro de Kalman

## Algoritmo



Predição




$$1D \quad bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - \bar{\mu}_t) \\ \sigma_t^2 = (1 - K_t)\bar{\sigma}_t^2 \end{cases}, K_t = \frac{\bar{\sigma}_t^2}{\bar{\sigma}_t^2 + \bar{\sigma}_{obs,t}^2}$$


$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = a_t\mu_{t-1} + b_tu_t \\ \bar{\sigma}_t^2 = a_t^2\sigma_{t-1}^2 + \sigma_{act,t}^2 \end{cases} \quad 1D$$

$$nD \quad bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t\bar{\mu}_t) \\ \Sigma_t = (I - K_tC_t)\bar{\Sigma}_t \end{cases}, K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t\mu_{t-1} + B_tu_t \\ \bar{\Sigma}_t = A_t\Sigma_{t-1}A_t^T + R_t \end{cases} \quad nD$$



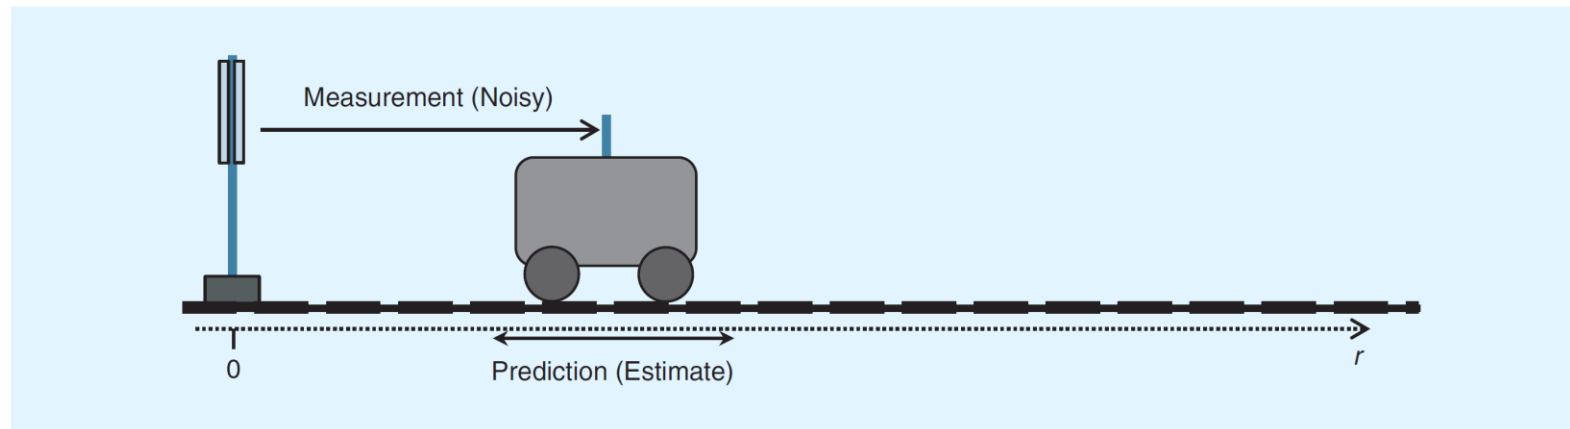
Correção



# Filtro de Kalman

## Exemplo

- Rastrear um robô que se move sobre um trilho reto (1D)
- Entrada do sistema considera frenagem ou aceleração
- Medição da distância via rádio a partir de uma estação base



Fonte: Understanding the Basis of the Kalman Filter via a Simple and Intuitive Derivation [Lecture Notes] R. Faragher. Signal Processing Magazine, IEEE , vol.29, no.5, pp.128-132, 2012.

# Filtro de Kalman

## Exemplo – Predição


- **Vetor estado:** posição, velocidade
- **Entrada de controle:** aceleração

$$\boldsymbol{\mu}_t = \begin{bmatrix} x_t \\ \dot{x}_t \end{bmatrix} \quad \boldsymbol{u}_t = \frac{f_t}{m} = a$$

$$\begin{bmatrix} \bar{x}_t \\ \bar{\dot{x}}_t \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}}_{A_t} \begin{bmatrix} x_{t-1} \\ \dot{x}_{t-1} \end{bmatrix} + \underbrace{\begin{bmatrix} (\Delta t)^2/2 \\ \Delta t \end{bmatrix}}_{B_t} \boldsymbol{u}_t$$

$$R_t = \begin{bmatrix} (0.25)^2 & 0 \\ 0 & (0.15)^2 \end{bmatrix}$$

$$\bar{\boldsymbol{\mu}}_t = A_t \boldsymbol{\mu}_{t-1} + B_t \boldsymbol{u}_t$$
$$\bar{\boldsymbol{\Sigma}}_t = A_t \boldsymbol{\Sigma}_{t-1} A_t^T + R_t$$



$$\boldsymbol{\mu}_0 = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \quad \boldsymbol{\Sigma}_0 = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

Fonte: Understanding the Basis of the Kalman Filter via a Simple and Intuitive Derivation [Lecture Notes] R. Faragher. Signal Processing Magazine, IEEE , vol.29, no.5, pp.128-132, 2012.


# Filtro de Kalman

## Exemplo – Correção

- Definir o mapeamento do espaço de estados para espaço de medição
- Vamos considerar apenas a posição

$$z_t = \begin{bmatrix} x_t^{radio} \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \end{bmatrix}}_{C_t} \begin{bmatrix} x_t \\ \dot{x}_t \end{bmatrix} \quad Q_t = [(0.20)^2]$$

$$K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$$
$$\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$$
$$\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$$

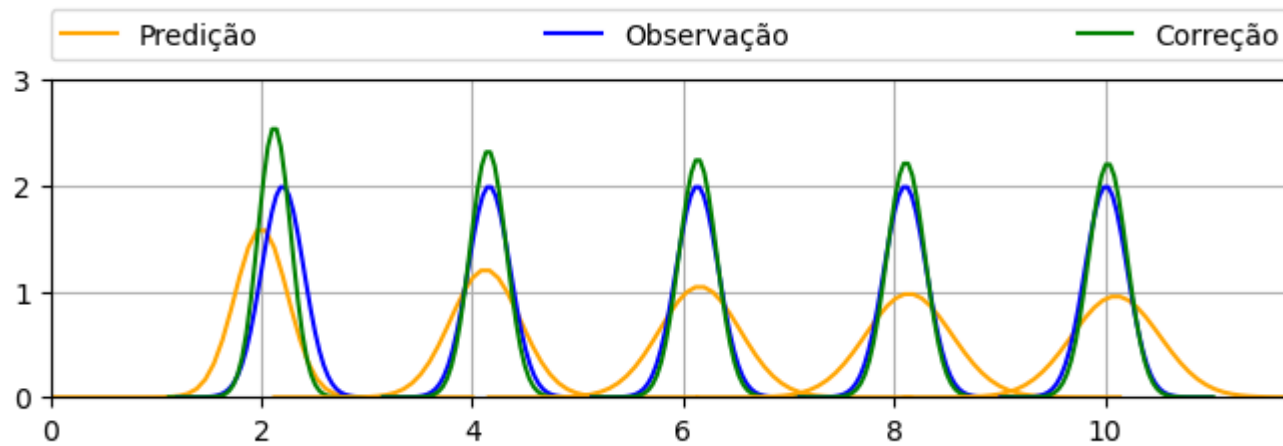


Fonte: Understanding the Basis of the Kalman Filter via a Simple and Intuitive Derivation [Lecture Notes] R. Faragher. Signal Processing Magazine, IEEE , vol.29, no.5, pp.128-132, 2012.


# Filtro de Kalman

## Exemplo

### Posição



### Velocidade



# Considerações finais

- Altamente eficiente
  - Custo polinomial considerando as dimensões dos vetores de estado ( $n$ ) e observação ( $k$ ) e operações básicas em matrizes
    - $O(k^{2,376} + n^2)$
- Estimador ótimo para sistemas lineares gaussianos
- Maioria dos sistemas robóticos é não-linear
  - Extensões para diferentes casos

# Considerações finais

## Extensões

- Extended Kalman Filter (EKF)
  - Linearização em torno no estado atual
  - Requer o cálculo de Matrizes Jacobianas
- Unscented Kalman Filter (UKF)
  - Linearização estocástica (amostragem)
  - Geralmente mais eficiente (mesmo custo!)
- Kalman-Bucy Filter (KBF)
  - Implementação contínua do KF
  - Utiliza algoritmos de integração numérica