

Robótica Móvel

Mapeamento – Occupancy Grid

Prof. Douglas G. Macharet
douglas.macharet@dcc.ufmg.br

Introdução

- Mapeamento é uma tarefa fundamental
 - Robôs com pouca/nenhuma supervisão
- Aplicações
 - Localização
 - Planejamento de caminhos
 - Tomada de decisão
 - ...

Mapeamento

Problemas

- Incertezas
 - Extrair informação de sensores ruidosos
 - Erros provenientes da atuação (localização)
- Ambiguidade
 - Estabelecer correspondência entre leituras
 - Loop-Closure (re-identificar local já visitado)
- Solução: representação baseada em probabilidades!

Occupancy Grid

- Algoritmo probabilístico
 - Proposto por Moravec e Elfes (1985)
- Principais considerações
 - Localização do robô é conhecida
 - Ambiente estático (mapa é “adaptável”)
- Utiliza uma representação em grid
- Facilita a integração de diferentes sensores


Occupancy Grid

- Cada célula i no grid é uma variável aleatória binária que modela a ocupação (obstáculo) na posição associada à célula
 - $p(m_i) = 0$ (vazio)
 - $p(m_i) = 1$ (ocupado)

A notação compacta $p(m_i)$ é usada para representar a probabilidade da célula estar **ocupada**, ou seja, $p(m_i = 1)$.
- Inicialmente, células com $p(m_i) = 0,5$ (desconhecido)
- Probabilidades nas células são independentes
- Mapa é a união das células: $m = \sum_i m_i \Rightarrow p(m) = \prod_i p(m_i)$


Occupancy Grid

Representação em tons de cinza facilita a visualização.




Occupancy Grid

Assume-se que posição do robô no ambiente é conhecida.




Occupancy Grid



Considerando a incerteza associada à percepção, as células são preenchidas com as probabilidades de estarem ocupadas.

Occupancy Grid

Assumimos que não existe correlação entre as células!



Occupancy Grid

- O objetivo é determinar a probabilidade a posteriori

$$p(m \mid z_{1:t}, x_{1:t})$$

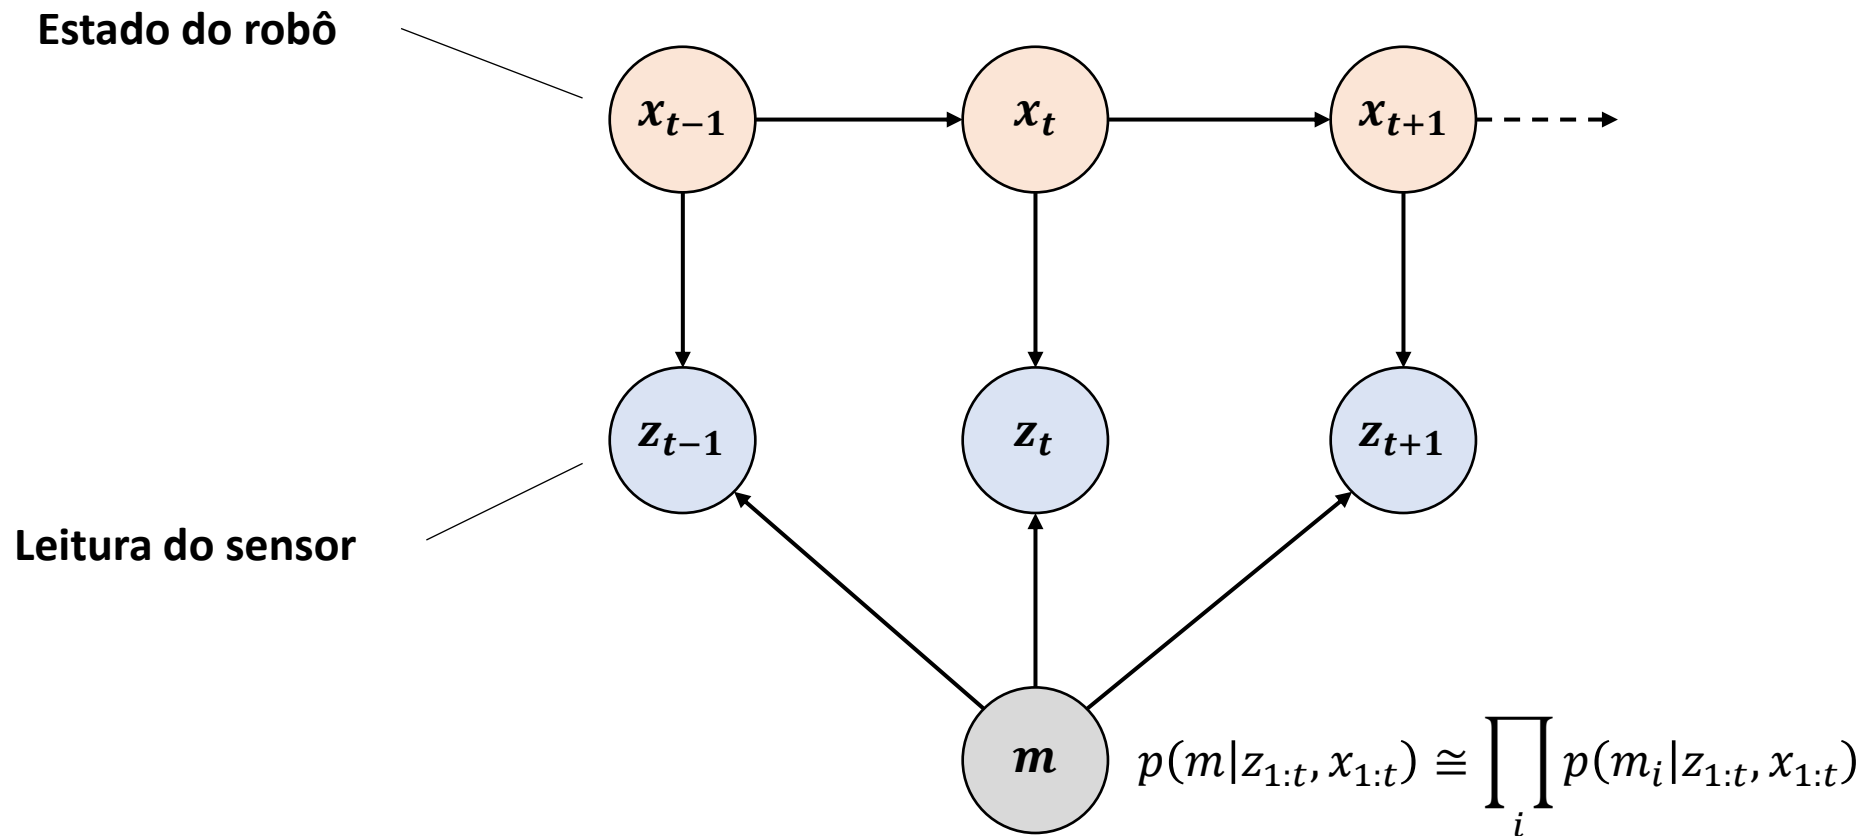
onde $z_{1:t}$ são as observações e $x_{1:t}$ o caminho do robô

- Se torna rapidamente intratável com o tamanho do mapa
 - Um grid 100×100 possui 2^{10000} mapas binários possíveis
- Para resolver fazemos uma aproximação

$$p(m \mid z_{1:t}, x_{1:t}) \cong \prod_i p(m_i \mid z_{1:t}, x_{1:t})$$

← probabilidade marginal

Occupancy Grid



Occupancy Grid

- Mas como calcular $p(m_i \mid z_{1:t}, x_{1:t})$?
- Teorema de Bayes Condicional

$$p(A \mid B, C) = \frac{p(B \mid A, C)p(A \mid C)}{p(B \mid C)}$$

Occupancy Grid

Bayes

$$p(m_i | z_{1:t}, x_{1:t}) = \frac{p(z_t | m_i, z_{1:t-1}, x_{1:t}) p(m_i | z_{1:t-1}, x_{1:t})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

Medição atual só
depende do estado atual
e da célula de mapa

Estado atual sem a medição atual
não fornece nenhuma informação
adicional sobre a ocupação da célula

Se C é independente de A
dado B, então C fornece
nenhuma informação extra
sobre A depois de sabermos B

$$p(A | B, C) = p(A | B)$$

Markov

$$p(m_i | z_{1:t}, x_{1:t}) = \frac{p(z_t | m_i, x_t) p(m_i | z_{1:t-1}, x_{1:t-1})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

Probabilistic Robotics (Cap. 2.4.4): The Markov assumption postulates that past and future data are independent if one knows the current state x_t .

Occupancy Grid

Bayes

$$p(z_t | m_i, x_t) = \frac{p(m_i | z_t, x_t)p(z_t | x_t)}{p(m_i | x_t)}$$



$$p(m_i | z_{1:t}, x_{1:t}) = \frac{p(m_i | z_t, x_t)p(z_t | x_t)p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i | x_t)p(z_t | z_{1:t-1}, x_{1:t})}$$

Estado atual sem a medição atual
não fornece nenhuma informação




Markov

$$p(m_i | z_{1:t}, x_{1:t}) = \frac{p(m_i | z_t, x_t)p(z_t | x_t)p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i)p(z_t | z_{1:t-1}, x_{1:t})}$$

Occupancy Grid

Prior




$$p(m_i | x_t)$$

**Modelo de
Observação**

$$p(z_t | m_i, x_t)$$



Posterior



$$p(m_i | z_t, x_t)$$

Occupancy Grid

- A manipulação direta de probabilidades pode ser difícil

$$p(m_i | z_{1:t}, x_{1:t}) = \frac{p(m_i | z_t, x_t) p(z_t | x_t) p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i) p(z_t | z_{1:t-1}, x_{1:t})}$$

- Uma forma de simplificar é usar a razão das probabilidades
 - Essa também é uma maneira de associar os eventos (occ, free)

$$p(\neg m_i | z_{1:t}, x_{1:t}) = \frac{p(\neg m_i | z_t, x_t) p(z_t | x_t) p(\neg m_i | z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) p(z_t | z_{1:t-1}, x_{1:t})}$$

Occupancy Grid

- Odds
 - Domínio: $[0, +\infty)$
 - Multiplicação das probabilidades cresce cada vez mais

$$o(A) = \frac{p(A)}{p(\neg A)} = \frac{p(A)}{1 - p(A)}$$

$$p(A) = \frac{o(A)}{1 + o(A)} = \frac{1}{1 + 1/o(A)}$$

Occupancy Grid

$$\frac{p(m_i | z_{1:t}, x_{1:t})}{p(\neg m_i | z_{1:t}, x_{1:t})} = \frac{\frac{p(m_i | z_t, x_t) \cancel{p(z_t | x_t)} p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i) \cancel{p(z_t | z_{1:t-1}, x_{1:t-1})}}}{\frac{p(\neg m_i | z_t, x_t) \cancel{p(z_t | x_t)} p(\neg m_i | z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) \cancel{p(z_t | z_{1:t-1}, x_{1:t-1})}}}$$

$$= \frac{p(m_i | z_t, x_t) p(m_i | z_{1:t-1}, x_{1:t-1}) p(\neg m_i)}{p(\neg m_i | z_t, x_t) p(\neg m_i | z_{1:t-1}, x_{1:t-1}) p(m_i)}$$

$$\frac{p(m_i | z_{1:t}, x_{1:t})}{1 - p(m_i | z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i | z_t, x_t)}{1 - p(m_i | z_t, x_t)}}_{\text{Utiliza } z_t} \underbrace{\frac{p(m_i | z_{1:t-1}, x_{1:t-1})}{1 - p(m_i | z_{1:t-1}, x_{1:t-1})}}_{p(\text{occ}) \text{ em } t - 1} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{Prior}}$$

Mapeamento

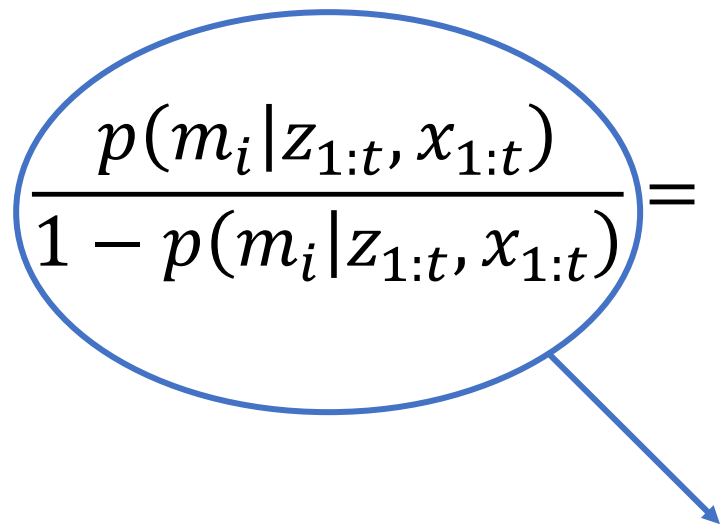
Probabilidade

- Log-odds
 - Domínio: $(-\infty, +\infty)$
 - Utilizado por razões de eficiência
 - Instabilidade numérica com probabilidades próximas de 0 ou 1
 - Evita problemas de truncamento pela multiplicação de probabilidades

$$l(A) = \log(o(A)) = \log\left(\frac{p(A)}{p(\neg A)}\right)$$

Occupancy Grid

- Representando os dois lados da equação com log-odds

$$\frac{p(m_i|z_{1:t}, x_{1:t})}{1 - p(m_i|z_{1:t}, x_{1:t})} = \frac{p(m_i|z_t, x_t)}{1 - p(m_i|z_t, x_t)} \frac{p(m_i|z_{1:t-1}, x_{1:t-1})}{1 - p(m_i|z_{1:t-1}, x_{1:t-1})} \frac{1 - p(m_i)}{p(m_i)}$$

$$l_{t,i} = l(m_i|z_{1:t}, x_{1:t}) = \log \left(\frac{p(m_i|z_{1:t}, x_{1:t})}{1 - p(m_i|z_{1:t}, x_{1:t})} \right)$$

Occupancy Grid

- A regra de atualização se baseia apenas na soma de termos

$$l(m_i | z_{1:t}, x_{1:t}) = \underbrace{l(m_i | z_{t-1}, x_{t-1})}_{\text{recursive term}} + \underbrace{l(m_i | z_t, x_t)}_{\text{inverse sensor model}} - \underbrace{l(m_i)}_{\text{prior}}$$

- De maneira ainda mais compacta

$$l_{t,i} = l_{t-1,i} + \text{inverse_sense_model}(m_i, x_t, z_t) - l_0$$

Occupancy Grid

- Pode-se recuperar a probabilidade a partir do log-odds

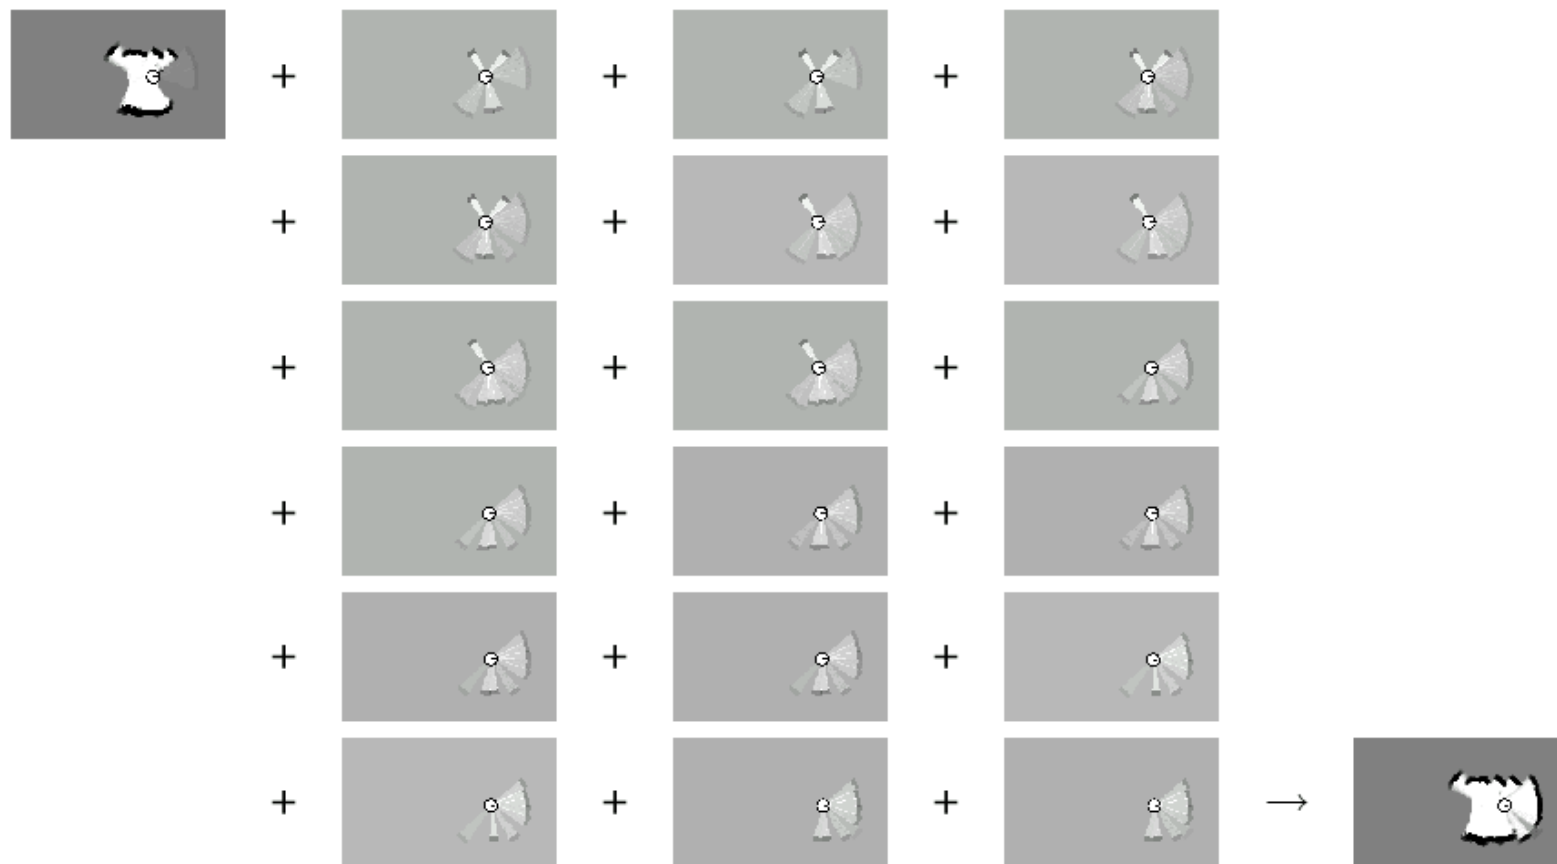
$$l_{t,i} = l(m_i | z_{1:t}, x_{1:t}) = \log \left(\frac{p(m_i | z_{1:t}, x_{1:t})}{1 - p(m_i | z_{1:t}, x_{1:t})} \right)$$

$$p(m_i | z_{1:t}, x_{1:t}) = \frac{1}{1 + \exp(l_{t,i})}$$

Occupancy Grid

```
1:  Algorithm occupancy_grid_mapping( $\{l_{t-1,i}\}, x_t, z_t$ ):  
2:    for all cells  $\mathbf{m}_i$  do  
3:      if  $\mathbf{m}_i$  in perceptual field of  $z_t$  then  
4:         $l_{t,i} = l_{t-1,i} + \text{inverse\_sensor\_model}(\mathbf{m}_i, x_t, z_t) - l_0$   
5:      else  
6:         $l_{t,i} = l_{t-1,i}$   
7:      endif  
8:    endfor  
9:    return  $\{l_{t,i}\}$ 
```

Occupancy Grid




Fonte: Occupancy Grid Mapping (Cyrill Stachniss)

Occupancy Grid

Inverse Sensor Model (Laser)

- O que a nova informação acrescenta em relação ao prior
 - Dada a medição, é mais provável que esteja ocupado ou livre?



Occupancy Grid


Inverse Sensor Model

```
1:   Algorithm inverse_range_sensor_model( $i, x_t, z_t$ ):
2:     Let  $x_i, y_i$  be the center-of-mass of  $m_i$ 
3:      $r = \sqrt{(x_i - x)^2 + (y_i - y)^2}$ 
4:      $\phi = \text{atan2}(y_i - y, x_i - x) - \theta$ 
5:      $k = \text{argmin}_j |\phi - \theta_{j,\text{sens}}|$ 
6:     if  $r > \min(z_{\text{max}}, z_t^k + \alpha/2)$  or  $|\phi - \theta_{k,\text{sens}}| > \beta/2$  then
7:       return  $l_0$ 
8:     if  $z_t^k < z_{\text{max}}$  and  $|r - z_{\text{max}}| < \alpha/2$ 
9:       return  $l_{\text{occ}}$ 
10:    if  $r \leq z_t^k$ 
11:      return  $l_{\text{free}}$ 
12:    endif
```

Atenção: esse código é para sonares (α, β), deve ser ligeiramente adaptado para lasers.

Occupancy Grid

Inverse Sensor Model



Fonte: *Probabilistic Robotics* (Cap. 9)

Occupancy Grid

Beam Models of Range Finders

- Probabilidades dependem do modelo do sensor
- Geralmente a medição é composta por leituras individuais
 - $z_t = \{z_t^1, \dots, z_t^K\}$
 - Aproximado pelo produto das probabilidades individuais

$$p(z_t | m, x_t) = \prod_{k=1}^K p(z_t^k | m, x_t)$$

- Modelo mais realista para $p(z_t | m, x_t)$
 - Considera ruídos e incertezas associadas à medição

Occupancy Grid

Beam Models of Range Finders


- Termos considerados
 - Ruído na medição
 - Objetos inesperados
 - Falhas
 - Aleatoriedades

$$p(z_t^k | x_t, m) = \begin{pmatrix} z_{\text{hit}} \\ z_{\text{short}} \\ z_{\text{max}} \\ z_{\text{rand}} \end{pmatrix}^T \cdot \begin{pmatrix} p_{\text{hit}}(z_t^k | x_t, m) \\ p_{\text{short}}(z_t^k | x_t, m) \\ p_{\text{max}}(z_t^k | x_t, m) \\ p_{\text{rand}}(z_t^k | x_t, m) \end{pmatrix}$$


```
1:  Algorithm beam_range_finder_model( $z_t, x_t, m$ ):
2:       $q = 1$ 
3:      for  $k = 1$  to  $K$  do
4:          compute  $z_t^{k*}$  for the measurement  $z_t^k$  using ray casting
5:           $p = z_{\text{hit}} \cdot p_{\text{hit}}(z_t^k | x_t, m) + z_{\text{short}} \cdot p_{\text{short}}(z_t^k | x_t, m)$ 
6:               $+ z_{\text{max}} \cdot p_{\text{max}}(z_t^k | x_t, m) + z_{\text{rand}} \cdot p_{\text{rand}}(z_t^k | x_t, m)$ 
7:           $q = q \cdot p$ 
8:      return  $q$ 
```

Occupancy Grid


Beam Models of Range Finders




(a) Gaussian distribution p_{hit}




(c) Uniform distribution p_{max}



(b) Exponential distribution p_{short}



(d) Uniform distribution p_{rand}



Occupancy Grid

Beam Models of Range Finders

■ Modelo simplificado

$$p(z_t | m, x_t) = \frac{1 + S_{occ}^z - S_{free}^z}{2}$$

Distância para o sensor Distância leitura Precisão


$$S_{occ}^z = \begin{cases} 1 & \text{se } d \in [r - \epsilon, r + \epsilon] \\ 0 & \text{caso contrário} \end{cases}$$
$$S_{free}^z = \begin{cases} 1 & \text{se } d \in [0, r - \epsilon) \\ 0 & \text{caso contrário} \end{cases}$$

■ Outra alternativa


- $p_{occ} \gg 0,5$: se a célula está perto da distância de medição
- $p_{occ} \ll 0,5$: se a célula está longe (entre o robô e a medição)
- Lembrando que $p_{free} = 1 - p_{occ}$

Occupancy Grid

- Precisamos percorrer o mapa todo a cada nova leitura?
 - Não!
 - Atualizar apenas as células associadas às leituras




Occupancy Grid



$$\begin{bmatrix} x_o \\ y_o \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} d \\ 0 \end{bmatrix} + \begin{bmatrix} x \\ y \end{bmatrix}$$

$$\begin{bmatrix} i \\ j \end{bmatrix} = \text{floor} \left(\frac{1}{r} \begin{bmatrix} x_o \\ y_o \end{bmatrix} \right)$$

Occupancy Grid



$$\begin{bmatrix} x_o^k \\ y_o^k \end{bmatrix} = \begin{bmatrix} d_k \cos(\theta + \alpha_k) \\ -d_k \sin(\theta + \alpha_k) \end{bmatrix} + \begin{bmatrix} x \\ y \end{bmatrix}$$

$$\begin{bmatrix} i^k \\ j^k \end{bmatrix} = \text{floor} \left(\frac{1}{r} \begin{bmatrix} x_o^k \\ y_o^k \end{bmatrix} \right)$$

Occupancy Grid



<https://youtu.be/aEeS8hDnnYg>

Considerações finais

Histograma

■ Contador

- $hits(x,y)$: Números de vezes que o sensor identificou um obstáculo na célula (x,y)
- $misses(x,y)$: Números de vezes que o sensor **não** identificou um obstáculo na célula (x,y)

$$p(m_i) = \frac{hits(x, y)}{hits(x, y) + misses(x, y)}$$

Considerações finais

- Convergência com o tempo
 - Probabilidades acumuladas (ocupado/vazio)
- Decisões baseadas em um limiar
 - $p(m_i) = 0,45$, está ocupado ou não?
- Problemas da utilização de um grid
 - Resolução, memória, processamento, ...
- A localização também possui incerteza!

